



## Pre-Fall - Sistema inteligente para la prevención y predicción de caídas

### E1.1 - Informe de estado de la técnica

Proyecto	Pre-Fall - Sistema inteligente para la prevención y predicción de caídas
Entregable	E1.1 - Informe de estado de la técnica
Fecha	31/5/2021

## Contenido

Contenido.....	1
Índice de figuras.....	2
Resumen Ejecutivo.....	3
1 Revisión de la bibliografía científica.....	4
1.1 Antecedentes.....	4
1.2 Método de adquisición de datos.....	5
1.2.1 Adquisición de datos basada en dispositivos no vestibles.....	6
1.2.2 Adquisición de datos basada en sensores vestibles.....	8
1.3 Ubicación de los sensores: variables evaluadas y tipo de pruebas realizadas.....	9
1.3.1 Ubicación de los dispositivos no vestibles.....	9
1.3.2 Ubicación de los sensores vestibles.....	11
1.4 Entornos de evaluación.....	12
1.5 Finalidad de las evaluaciones.....	12
1.6 Técnicas de análisis de datos.....	13
2 Dispositivos comerciales existentes para la detección de movimiento.....	16
2.1 Dispositivos no vestibles.....	16
2.1.1 Sistemas de captura de movimiento.....	16
2.1.2 Plataformas de fuerza.....	18
2.1.3 Superficies instrumentadas.....	18
2.2 Sistemas vestibles enfocados al entorno deportivo.....	19
2.3 Otros sistemas basados en sensores inerciales.....	20
2.3.1 LEGSys.....	21
2.3.2 Kinesis Gait.....	22
2.3.3 PhysiGait Live.....	23
2.3.4 iSen System.....	23
2.3.5 RehaGait.....	24
2.3.6 G-Walk.....	25
3 Conclusiones.....	27
4 Referencias.....	28

## Índice de figuras

Figura 1. Ciclos de la marcha.....	4
Figura 2. Diferentes configuraciones del entorno de pruebas con sistemas de detección y análisis de movimiento a través de vídeo.....	17
Figura 3. Kinect en su versión original (izquierda) y en la versión 2 (comercializada a partir de 2014).....	17
Figura 4. Azure Kinect DK.....	18
Figura 5. Sistema GAITRite.....	19
Figura 6. Sensor running Bluetooth Smart de Polar (izquierda) y SmartTracks de Humotion (derecha).....	20
Figura 7. SmartSocks (izquierda) y Digisole (derecha).....	20
Figura 8. LEGSys.....	22
Figura 9. Kinesis GAIT.....	23
Figura 10. PhysicaGait Live.....	23
Figura 11. iSEN Systems.....	24
Figura 12. RehaGait.....	25
Figura 13. G-Walk.....	26

## Resumen Ejecutivo

El estudio del estado de la técnica de la tecnología de análisis de la marcha se ha dividido en dos grandes grupos.

En primer lugar (Sección 1), se realiza una revisión literaria de diferentes artículos científicos, seleccionando 25 como los más relevantes en el contexto del análisis de la marcha. De dichos artículos, se pretende extraer sus características acerca del método de captación de datos, ubicación de los sensores y finalidad de las evaluaciones. Los artículos seleccionados abarcan no sólo los que utilizan los sensores inerciales vestibles, sino también los que utilizan otros métodos de captación, tratando así de obtener una visión global. Se analizan, además, las técnicas de análisis de datos utilizadas para el modelado de la marcha en los artículos seleccionados.

Por otro lado (Sección 2), se realiza una búsqueda de los sistemas comerciales existentes para la detección del movimiento en la actualidad.

## 1 Revisión de la bibliografía científica

### 1.1 Antecedentes

La marcha humana es una tarea compleja e integrada que requiere una coordinación precisa del sistema neuronal y musculoesquelético para garantizar la correcta dinámica esquelética. El ciclo de la marcha es un fenómeno periódico que se define como el intervalo entre dos eventos consecutivos (generalmente contacto entre el talón y el suelo) del mismo pie. Se caracteriza por una **fase de postura** (60% del ciclo de marcha total), donde al **menos un pie está en contacto con el suelo** y una fase de **oscilación** (40% del ciclo de marcha total), durante el cual una **extremidad se balancea** hasta el próximo contacto del talón con el suelo. Las fases de la marcha pueden ser bastante diferentes entre individuos, pero cuando se normalizan en un porcentaje del ciclo de la marcha mantienen una estrecha similitud. La siguiente figura muestra dos imágenes sincronizadas diferentes. La imagen superior traza un boceto de una persona que representa las diferentes fases de la marcha con la extremidad derecha en negrita. La imagen en la parte inferior representa el período de tiempo desde un evento (generalmente contacto inicial) de un pie hasta la aparición posterior del contacto inicial del mismo pie.

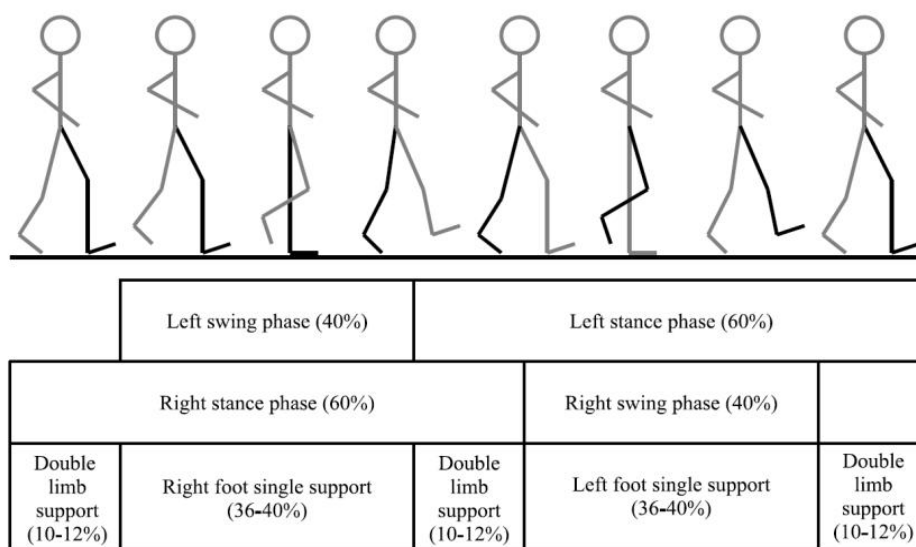


Figura 1. Ciclos de la marcha

Existe un consenso a la hora de considerar tanto a la marcha humana como a la postura como un parámetro biométrico, los cuales a diferencia de otros biomarcadores usados tradicionalmente, como pueden ser las huellas dactilares, el iris, la retina, el ADN y la cara, pueden conseguirse a largas distancias y a una resolución baja. Así, pueden establecerse los **diferentes patrones de caminar que tienen las personas**, y, de esa manera, analizar cualquier desviación que puede implicar una **patología del individuo**, como puede ser la **hemorragia cerebral**, **Parkinson** u otras enfermedades neurodegenerativas. En ese ámbito, caben destacar

los trabajos realizados por Tan et al. (2018), El-Attar et al. (2019), Shetty et al. (2019), Camps et al. (2017).

Otros artículos han analizado los dos componentes de la marcha (equilibrio y pose) con el objetivo de prevenir, diagnosticar, y rehabilitar la posible pérdida de independencia por discapacidad, o envejecimiento, como son los de Costilla-Reyes et al. (2018), Seyfioğlu (2017), Paragliola et al. (2018), Balazia et al. (2017).

El análisis de la marcha se ha venido utilizando por los facultativos o fisioterapeutas para evaluar las anomalías en la marcha o identificar cambios como consecuencia de las intervenciones. Los análisis biomecánicos de la marcha tienen generalmente en cuenta variables de la marcha de tipo discreto (velocidad de la marcha, longitud del paso), pero cuando las variables a analizar se extraen de variables continuas, muchos datos no son tenidos en cuenta, quedando sin esclarecer la forma en que las variables pre-seleccionadas son capaces de dar una representación de todo el movimiento de cuerpo como la marcha humana. La selección de las variables más representativas de la marcha es subjetiva y puede perder información potencialmente relevante, de ahí que las técnicas de machine learning, como pueden ser redes neuronales y support vector machines (SVM), se hayan comenzado a usar recientemente para examinar el desplazamiento humano, utilizando un comportamiento de la marcha en tiempo continuo (Horst et al. 2018).

El análisis de la marcha clínica es un proceso por el cual se recoge la información cuantitativa para ayudar en la toma de decisiones acerca de la etiología de las no normalidades de la marcha y el tratamiento. El análisis de la marcha se desarrolla utilizando tecnología diversa como puede ser videocámaras, o sensores electromagnéticos o por inercia, que miden el movimiento de los pacientes, o incluso con electrodos situados en la parte superficial de la piel para medir la actividad del músculo. Existen laboratorios clínicos, en los que es posible conseguir parámetros biomédicos bastante exactos, pero el problema se presenta en el coste de material y las restricciones físicas a la hora de medir la marcha fuera del entorno ambulatorio. Por ello, ha existido un creciente interés a la hora de desarrollar dispositivos vestibles por su bajo coste de producción y portabilidad, así como para permitir medir los parámetros de la marcha de manera diaria, reduciendo el estrés y la ansiedad.

## 1.2 Método de adquisición de datos

El primer paso a tener en cuenta para poder realizar un análisis de la marcha es determinar cómo llevar a cabo la adquisición de los datos de partida. Dicha adquisición de datos puede realizarse de maneras muy diversas según el tipo y disposición de los sensores utilizados. Teniendo en cuenta la bibliografía analizada pueden dividirse los métodos de adquisición de datos dos grandes grupos según caractericemos a los sensores en vestibles y no vestibles.

A continuación, se detallan las principales características de cada método de adquisición y varios estudios representativos que los utilizan.

### 1.2.1 Adquisición de datos basada en dispositivos no vestibles

La tecnología no vestible proporciona una adquisición de datos muy precisa, pero necesita laboratorios específicamente dedicados para este fin, por lo que su aplicación resulta mucho más cara que el caso de los dispositivos vestibles.

Las tecnologías de este tipo pueden dividirse en tres grandes grupos (Shanahan et al. 2018):

- Sistemas de captura de movimiento.
- Plataformas de fuerza.
- Superficies instrumentadas.

A continuación, se especifican las principales características de cada grupo.

#### 1.2.1.1 Sistemas de captura de movimiento

Este tipo de métodos se basan en el uso de uno o varios dispositivos que captan la imagen de la persona y un software que permite identificar la posición de las diferentes partes del cuerpo. Se dividen, a su vez, en dos grupos:

- **Sistemas basados en marcadores:** necesitan el uso de algún tipo de marcador en el cuerpo del usuario para establecer su posición.
- **Sistemas no basados en marcadores:** no necesitan que el usuario disponga de ningún marcador en su cuerpo.

##### 1.2.1.1.1 Sistemas basados en marcadores

La tecnología estándar utilizada para el análisis de la marcha son los sistemas **opto electrónicos** (llamados así ya que unen los sistemas **ópticos**, y **electrónicos**). Se basan en una serie de **dispositivos de captación de imagen** que deben ser **complementados con marcadores reflectantes** en el cuerpo de la persona. Estos sistemas proporcionan una **gran exactitud** en medir los rasgos **cinemáticos**. Sin embargo, tienen como **gran inconveniente** un **coste más elevado** y muchas limitaciones en el **entorno de pruebas** a realizar ya que deben llevarse a cabo en entornos **muy controlados**. Además, son **más intrusivos** para los **usuarios finales**, que necesitarán utilizar unos **marcadores especiales** en determinadas partes del cuerpo que deben ser colocados por profesionales, ya que su **localización** debe ser muy **precisa**.

Estas técnicas pueden combinarse con platos de fuerza (**bloques de acero equipados con traductores piezoeléctricos**, y **extensómetros**, más información en Sección 1.2.2.1), para **recoger las fuerzas de reacción del suelo**, o **electromiografía**, para recoger las **fuerzas de reacción y la activación del músculo**, permitiendo la **evaluación simultánea de la cinemática y las fuerzas**.

Algunos de los estudios más recientes que han utilizado esta técnica para el análisis de las características de la marcha son los siguientes: **Horst et al. (2019)**, **Pogorelc et al. (2012)**.

#### 1.2.1.1.2 Sistemas no basados en marcadores

Los sistemas de captación de imagen que no necesitan marcadores en el cuerpo se basan en una serie de sensores RGB y sensores de profundidad que obtienen datos en tiempo real de las posiciones del usuario. Mediante técnicas de análisis de dichas imágenes se pueden extraer las características deseadas, por ejemplo, la posición en el espacio en 3D de alguna parte del cuerpo. No son métodos tan fiables y exactos como los sistemas basados en marcadores, pero resultan más baratos de implantar y consiguen resultados científicamente aceptables.

Uno de los dispositivos más extendidos para llevar a cabo este tipo de estudios en la bibliografía es el Kinect (ver más detalles en Sección 2.1.1.2). El gran potencial de este dispositivo son sus librerías de detección de movimiento que permiten obtener en tiempo real y con gran precisión las posiciones de 25 puntos del cuerpo a una velocidad de 30 frames por segundo.

La recogida y el tratamiento de estos datos permiten realizar los análisis necesarios con un coste bajo. Aun así, existen varias limitaciones, como pueden ser el rango de movimiento (tienen un área funcional limitada), la luz (la precisión de los resultados se verá influida por la calidad de la iluminación) y la oclusión (el sistema tiene deficiencias cuando partes del cuerpo del usuario se encuentran tras objetos, impidiendo una visión lo suficientemente completa del cuerpo del usuario para que los algoritmos detecten su posición).

Algunos de los estudios más recientes que han utilizado esta técnica para el análisis de las características de la marcha son los siguientes: Andersson et al. (2015), Tan et al. (2018), Sahak et al. (2018), Uddin et al. (2017).

#### 1.2.1.2 Plataformas de fuerza

Las plataformas de fuerza están formadas por unos bloques de acero equipados con transductores piezoeléctricos que miden las fuerzas de reacción sobre el suelo. Se han usado en diversos estudios para obtener valores relativos a la marcha, equilibrio y postura corporal (Meshkati et al. 2011).

Este tipo de sistemas necesita un ambiente de laboratorio para llevar a cabo las pruebas, por lo que tienen un coste alto. Sin embargo, se han desarrollado alternativas más baratas, como la Nintendo Wii Balance Board que, además de su bajo coste, permite una fácil portabilidad. Varios estudios han demostrado la validez científica de esta plataforma para medir variables relacionadas con el equilibrio (Bartlett et al. 2014).

#### 1.2.1.3 Superficies instrumentadas para detección de pisadas

Este tipo de dispositivos consisten en una superficie en la que se integran una serie de sensores capaces de identificar el contacto de la persona sobre la superficie. Existen varios dispositivos comerciales de este tipo (ver Sección 2.1.3). Además, diversos trabajos exploran la creación de nuevos dispositivos, como la superficie inteligente “iMAGiMAT” en Costilla-Reyes et al. (2018), basado en trabajos previos de



Cantoral-Ceballos et al. (2015). Esta denominada “alfombra inteligente” está compuesta por fibras ópticas plásticas, sensibles a la deformación cuando se ejerce cierta presión a la hora de caminar. Se trata de una técnica novedosa basada en una combinación innovadora de hardware y software de tomografía no planar, que permite la reconstrucción de las pisadas en la superficie de la alfombra.

Este tipo de dispositivos son muy precisos para obtener parámetros relevantes de la marcha, pero tienen el inconveniente de que proporcionan poco rango de movimiento, ya que los usuarios sólo pueden realizar un número limitado de pasos, debido a las restricciones de tamaño de la superficie.

### 1.2.2 Adquisición de datos basada en sensores vestibles

Los sensores vestibles han sido desarrollados para medir de forma detallada la cinemática de la marcha en la vida diaria. Pueden situarse en varias partes del cuerpo (debajo del pie, tobillo, muñeca, cadera), dependiendo de los requisitos.

Dentro de este grupo de sensores puede definirse, a su vez, dos subgrupos:

- Sensores que miden la presión.
- Sensores que miden la inercia.

#### 1.2.2.1 Sensores vestibles que miden la presión

Este tipo de sensores son instrumentos aislados, situados o integrados en el zapato (generalmente en forma de plantillas), para medir cambios en la presión entre el pie y el suelo. Son comparables a las plataformas de fuerza (ver Sección 1.2.1.2) y también miden la fuerza del suelo sobre el pie, pero, a diferencia de éstas, mide la fuerza independientemente de sus componentes y sus direcciones (ejes x, y, z). Estas medidas de presión plantar permiten calcular las variables espacio-temporales de la marcha.

Algunos de los estudios más recientes que utilizan este tipo de medidas para llevar a cabo un análisis de la marcha son los siguientes: Shetty et al. (2016), Mohammed et al. (2014) y Lee et al. (2019).

#### 1.2.2.2 Sensores vestibles que miden la inercia

Miden la aceleración del objeto, y pueden usarse para informar de la velocidad, orientación y fuerzas gravitacionales. Al tratarse de dispositivos pequeños, pueden ser integrados fácilmente en las prendas de vestir, por lo que se consideran dispositivos vestibles.

Los sensores inerciales consisten, generalmente, en la combinación de un acelerómetro en tres ejes, un giroscopio en tres ejes y un magnetómetro en tres ejes, generando datos cinemáticos tanto espaciotemporales como en 3D, incluyendo articulaciones y ángulos de segmentos. Igual que en el caso de los sensores de presión, pueden integrarse en plantillas muy útiles para medir la marcha, pero también se pueden situar en diversos puntos del cuerpo, como la cintura o muñeca.

Los **sensores de inercia** son los sistemas que más se usan para la marcha y el análisis de equilibrio, y en la literatura científica han sido **probados tanto en voluntarios sanos como en grupos con discapacidad motora**. Diversos estudios han resaltado su validez científica para determinar los valores del movimiento humano, como los de **El-Attar et al. (2019)**, **Wang et al. (2017)** o **Paragliola et al. (2018)**, siendo uno de los más representativos la revisión sistemática de **Caldas et al. (2017)** que concluye que los **sensores inerciales** son un método válido para obtener parámetros relevantes de la marcha humana.

### **1.3 Ubicación de los sensores: variables evaluadas y tipo de pruebas realizadas**

Dependiendo del tipo de adquisición de datos, se debe analizar dónde se ubican los sensores, qué tipo de variables y qué tipo de pruebas se realizan para recoger datos científicamente válidos para el análisis de la marcha.

#### **1.3.1 Ubicación de los dispositivos no vestibles**

##### **1.3.1.1 Sistemas de *captura de movimiento***

En esta sección se distinguen por un lado los trabajos en los que se han realizado las pruebas de adquisición de datos mediante algún sistema de captura de movimiento (tanto con marcadores como sin marcadores) y, por otro lado, los estudios que se basan en la obtención de características de la marcha a partir de un conjunto de imágenes o vídeos ya existentes, disponibles generalmente en bases de datos previamente diseñadas y etiquetadas.

##### **1.3.1.1.1 Sistemas basados en marcadores**

Entre la bibliografía analizada, destacamos los siguientes estudios con sistemas basados en marcadores:

En **Balazia et al. (2017)**, las personas que llevaron a cabo los experimentos vestían un **mono negro con 41 marcadores sobre él**. Se movían en un espacio de **30 m<sup>2</sup>**, rodeados por **12 cámaras**, a una altura de 2 y 4 metros sobre el suelo.

**Horst et al. (2019)** utilizaron una serie de **cámaras de infrarrojos Ten Oqus 310** que **recogen las trayectorias de los marcadores tri-dimensionales colocados a lo largo del cuerpo**, complementando el análisis con **dos platos de fuerza situados en el suelo**. El software **Qualisys Track Manager 2.7** se utilizó para gestionar los resultados, asegurando su sincronización.

En **Pogorelc et al. (2012)** se utiliza un **sistema de captura de movimiento basado en 6 cámaras de infrarrojos y 12 etiquetas en el cuerpo**, situadas en los **hombros, codos, muñecas, caderas, rodillas y tobillos**, para un total de 9 personas, tanto sanas como con hemiplejía.

#### 1.3.1.1.2 Sistemas no basados en marcadores

Dentro de los experimentos llevados a cabo con el dispositivo Kinect, se destacan los siguientes procedimientos:

Tan et al. (2018) midieron el test HGS (*Habitual Gait Speed*) y el TUG (*Timed Up and Go*) modificado.

Sahak et al. (2018) definieron un experimento en el que las personas debían caminar de manera repetida hasta 10 veces, utilizando su ritmo normal en una senda arbitraria.

Para evitar la restricción de la distancia mínima requerida por Kinect para poder analizar a la persona, Andersson et al. (2014) idearon un sistema para que las personas caminasen en frente del sensor en una trayectoria semi-circular, de manera paralela, con la ayuda de un plato giratorio sobre el que se colocaba el Kinect para que el sensor pudiese seguir a la persona mientras caminaba. Las pruebas en este estudio consistieron en realizar 5 vueltas en esta trayectoria.

#### 1.3.1.1.3 Bases de datos de imágenes o vídeos de movimiento

Existen varios estudios que se basan en el análisis de características de la marcha a partir de bases de datos que contienen imágenes obtenidas a partir de dispositivos de captura de movimiento. Entre estos estudios se encuentran los de:

Shetty et al. (2016), que utilizaron datos obtenidos a partir de “*The National institutes of health -sponsored research resources for complex physiological signals*”.

Hoffman et al. (2014), quienes utilizan la base de datos gratuita y libre TUM Gait from Audio, Image and Depth (GAID). Dicha base de datos es la primera que permite de manera simultánea reconocer a las personas y seleccionar las cualidades usando múltiples modalidades. Dicha base de datos también dispone de un conjunto de etiquetas que permite reconocer las variables biométricas. Las imágenes que conforman esta base de datos se han obtenido utilizando una cámara situada a 1.9 m de alto, apuntando hacia abajo en un ángulo de 13°. Para generar esta base de datos, los individuos debían caminar de manera perpendicular a la línea de visión a lo largo de una distancia de 4 m. Típicamente la persona hace entre 1.5 y 2.5 ciclos de marcha en cada secuencia, durando alrededor de 2, 3 segundos cada ciclo. Mediante estas técnicas se han recogido datos de 305 individuos obtenidos en 2 sesiones diferentes, habiendo 32 personas registradas en ambas sesiones.

Battistone et al. (2018) utilizaron el conjunto de datos de CASIA - una gran base de datos formada por videos de 124 personas, grabadas de 11 diferentes posiciones (de 0 a 180°), realizadas en un entorno cerrado. En las grabaciones se utilizan variaciones (vestir diferentes ropas, abrigos y llevar objetos como una bolsa). Se obtiene una secuencia de 10 videos para cada persona.

Zhao et al. (2018) realizaron un entrenamiento y extracción de características a partir de una colección de imágenes, obtenidas en ambientes públicos alrededor de un campus universitario. Se trataba de una colección de datos de diferentes personas

realizando diversas actividades dentro del campus: caminar, sentarse, subir o bajar las escaleras, esperar por ascensores, abrir puertas, hablar con amigos. Como resultado, se etiquetaron de forma manual 2000 imágenes.

### **1.3.1.2 Superficies instrumentadas para detección de pisadas**

Costilla-Reyes et al. (2018) y Cantoral-Ceballos et al. (2015) utilizaron una superficie instrumentada para simular la marcha humana en 3 escenarios distintos: aeropuerto (40 personas), lugar de trabajo (15 personas) y hogar (5 personas). Se permitían al menos 2 ciclos de marcha (de 4 a 5 pasos consecutivos) para cada persona.

### **1.3.2 Ubicación de los sensores vestibles**

#### **1.3.2.1 Sensores vestibles que miden la presión**

En los sensores vestibles de tipo presión, Lee et al. (2019) utilizaron la **plantilla inteligente Footlogger** para **recoger los datos de la marcha**, que se transmiten posteriormente mediante **bluetooth a un Smartphone**.

Mohammed et al. (2014) **utilizaron un sistema de mapeo de movimiento** para transmitir los datos de presión y fuerza de los sensores situados en el zapato hacia el ordenador. Las pruebas consistieron en **5 ciclos caminando a una velocidad normal**.

#### **1.3.2.2 Sensores vestibles que miden la inercia**

El análisis de las características de los estudios basados en **sensores inerciales** es fundamental para poder determinar el tipo y la posición de los dispositivos.

La bibliografía analizada difiere tanto en el número de sensores como en su posición. Destacamos a continuación varios de los estudios más representativos:

Moore et al. (2013) realizaron una investigación exhaustiva acerca de diferentes configuraciones de sensores inerciales para detectar problemas derivados de la marcha en las personas diagnosticadas con Parkinson. Para ello realizó a un grupo de 25 pacientes diversas pruebas basadas en el test **"Timed Up and Go"**, **con una media de 5 repeticiones cada uno, en las que debían caminar 5 metros y volver al punto de partida**. Cada persona disponía de 7 sensores: zona lumbar, en la zona lateral de los muslos y de las pantorrillas y en la parte superior de los pies. Tras el análisis de los datos obtenidos se determinó que los sensores de las pantorrillas ofrecían **medidas comparables al conjunto de los 7 sensores y que** incluso era válido el uso de un **único sensor en la zona lumbar**. En esta misma línea de investigación, Camps et al. (2017) realizó un experimento con 21 pacientes con Parkinson, con una media de edad de 69, 29 años utilizando un único sensor inercial situado en la parte izquierda de la cadera del paciente.

En el trabajo de Lopez-Nava et al. (2015), se utilizaron dos sistemas ZStar3 en los tobillos (a 5cm sobre el maléolo) y se validó la precisión de los datos recogidos utilizando el sistema GAITRITE (ver Sección 2.1.3). Los test se realizaron en 7 mujeres y 3 hombres (edad entre 25 y 69) sin evidencia en desórdenes de la marcha. El test realizado consistía en caminar descalzo durante 7.6 metros, en línea recta, a

un ritmo de caminar cómodo. Se realiza la prueba 3 veces, siendo únicamente utilizada para el análisis la tercera repetición.

El-Attar et al. (2018) definieron un conjunto de 3 sensores situados en los tobillos y en la cadera. Para probar su validez utilizó un grupo de 10 personas, que debían hacer diferentes tareas, como caminar en línea recta, caminar y regresar al punto de partida y desarrollar actividades de la vida diaria.

Paragliola et al. (2018) utilizaron sensores inerciales en los zapatos de 60 personas (pacientes con Parkinson y pacientes sanos). Cada persona tuvo que caminar 77 metros a lo largo de un hall durante 5 minutos.

## 1.4 Entornos de evaluación

La gran mayoría de estudios analizados se llevan a cabo en un entorno clínico cerrado, debido en muchos casos a las restricciones propias de los sistemas de adquisición de datos y a la definición del propio experimento.

Destacamos a continuación los principales entornos no clínicos utilizados para llevar a cabo los estudios de la marcha:

Lee et al. (2019) definieron un entorno de pruebas al aire libre en el que se midieron siete tipos de marcha: caminar, caminar rápido, correr, subir y bajar escaleras, subir y bajar una pendiente. Los tipos de caminar, caminar rápido y correr se midieron durante 3 minutos. Para subir y bajar pendientes y escaleras, se midió desde el punto de inicio hasta el de llegada, sin considerar el tiempo que tardasen (uno o dos minutos). Los datos de la marcha fueron obtenidos a partir de 14 adultos entre los 20 y 30 años.

Camps et al. (2016) utilizaron la casa de cada paciente como entorno de evaluación. El experimento se llevó a cabo mientras los sujetos realizaban distintas actividades de la vida diaria, llevando consigo el sensor de inercia en la cadera. Los sujetos debían realizar las siguientes acciones: levantarse de la silla al sofá, caminar 6 metros, dar un giro de 180 grados, volver a caminar 6 metros, hacia la silla y el sofá, y sentarse. Además, otras actividades especiales se registraron para aumentar la complejidad del estudio: limpiar una taza, llevar un vaso de agua, mecanografiar en el ordenador, limpiarse los dientes, dibujar en una hoja.

Cabe resaltar que, en lo referente al entorno de pruebas, diversos estudios, como los de Seyfioğlu et al. (2017) y Wang et al. (2019), han demostrado que si los experimentos se llevan a cabo en el hogar pueden desaparecer el estrés y la ansiedad que supone realizar las pruebas en un ambiente hospitalario.

## 1.5 Finalidad de las evaluaciones

En todos los casos la finalidad de los trabajos analizados consiste en medir los rasgos típicos de la marcha, tanto espaciales como temporales y de esa forma, analizar las anomalías en el equilibrio y en la posición al caminar, que pueden estar relacionadas con enfermedades neurodegenerativas y discapacidad. La mayoría de los estudios

analizados se han centrado en la **enfermedad de Parkinson**: Shetty et al. (2016), Camps et al. (2017), Tan et al. (2018), El-Attar et al. (2018).

Hay otros estudios que se centran en el papel biométrico del análisis de la marcha con el fin último de poder determinar las características específicas que hacen de la marcha un rasgo único para cada persona. Dentro de esta línea, destaca Costilla-Reyes et al. (2018), que permiten distinguir a una persona determinada entre un conjunto de personas. Por su parte, Battistone et al. (2018), Balazia et al. (2017), Andersson et al. (2014), consiguen reconocer, la totalidad de las características del cuerpo, incluyendo medidas antropométricas y rasgos de la marcha dinámicos del comportamiento al caminar.

La **calidad de la marcha también se analiza para asegurar la capacidad de que una persona pueda vivir durante el mayor tiempo posible de manera autónoma en su propio hogar**. En este sentido, estudios como los de Uddin et al. (2017) se basan en utilizar sensores en el hogar para analizar la calidad de sus movimientos y evitar tanto caídas como deterioros cognitivos.

## 1.6 Técnicas de análisis de datos

A continuación, se detallan algunos estudios que se basan en modelos tradicionales como la **regresión lineal**, si bien la mayoría usa técnicas de **machine learning más avanzadas**. Del mismo modo, puede observarse como las redes neuronales presentan el tipo de estructura más utilizada en el ámbito del análisis de las características de la marcha.

Tan et al. (2018) utilizaron modelos de **regresión lineal multivariable con la finalidad de comprobar la fiabilidad de predecir con Kinect problemas en la marcha asociados al Parkinson**. Para ello se **utilizaron como datos para la validación los resultados de los instrumentos de medida Unified Parkinson's Disease Rating Scale (UPDRS) e Instability and Gait Difficulty (IGD)**.

Mohammed et al. (2014) realizaron una segmentación de las medidas de su estudio (específicamente controla el centro de fuerza del cuerpo humano mediante un sistema de medición de presión) para asociarlas a las diferentes fases de las que consta cada ciclo de la marcha. Para ello se modela cada segmento con un modelo de regresión y se utilizan funciones logísticas para modelar la transición entre segmentos.

Pogorelc et al. (2012) realizan una comparativa de diferentes técnicas de *Machine Learning* aplicadas al contexto de la marcha. Las **técnicas que mejores resultados ofrecieron fueron las de los K-vecinos más próximos y las redes neuronales (con 3 capas y 9 neuronas en la capa oculta)**, mientras que el **peor resultado fue para los árboles de decisión**. Otras técnicas utilizadas fueron las **SVM, random forest y naïve Bayes**.



Sahak et al. (2019) se centran en estudiar en detalle diferentes algoritmos de clasificación para las SVM, concluyendo que la aproximación que mejor se adapta a este contexto es la de *one-versus-all* (OVA).

Lee et al. (2019) diseñan una red neuronal convolucional profunda (*Deep Convolutional Neural Network*) para determinar qué tipo de marcha se está llevando a cabo, tomando como referencia los siguientes siete tipos: caminar, caminar rápido, correr, subir y bajar escaleras, subir y bajar una pendiente. Para ello se crea un modelo de extracción de características de los datos (en forma de series temporales) de presión, aceleración y giro y se combina para obtener un algoritmo de clasificación.

Camps et al. (2019) resaltan las ventajas de los métodos de *Deep Learning* respecto a los más tradicionales de *Machine Learning*, ya que indica que con el *Deep Learning* se pueden solventar mejor los aspectos de trabajar con datos multimodales, con datos incompletos y con espacios de características de grandes dimensiones. Con esta base diseña una red neuronal convolucional para el análisis de las series temporales.

Costilla-Reyes et al. (2018) utilizan una arquitectura basada en una red de tipo ResNet (*Residual Network*). Se trata de un concepto basado en las redes neuronales profundas que añade mejoras en el rendimiento al tratar un número elevado de capas. Se utilizan también modelos *Support Vector Machine* (SVM). La red neuronal toma como entrada dos flujos de datos: espaciales y temporales correspondientes y posteriormente se combinan.

Seyfioğlu et al. (2017) usan una red neuronal no supervisada, cuyo objetivo consiste en aprender de una representación de sus inputs, distribuida en 3 capas. El rendimiento obtenido con esta estructura es superior al uso de un clasificador SVM con los mismos datos de entrada.

Battistone et al. (2018) usan una red neuronal recurrente profunda, que permite clasificar directamente las secuencias de datos sin una segmentación. En este caso, la red neuronal aprende tanto de las articulaciones de los rasgos del esqueleto, como también de la información extraída de los cambios en las matrices adyacentes a lo largo del tiempo. En base a esto se crea el modelo denominado TGLSTM (*Time based Graph Long Short- Term Memory*) que explota conjuntamente datos estructurales e información temporal a través de una red neuronal que permite aprender de las dependencias y de la estructura del grafo.

El-Attar et al. (2019) utilizan la Transformada de Wavelet Discreta para extraer las características inherentes en la marcha. Posteriormente se evaluaron las capacidades de discriminación de estas características mediante un clasificador SVM y una red neuronal de dos capas.

Zhao et al. (2018), generan una red neuronal profunda para estimar la posición de la zona del cuerpo de la persona que no se encuentra visible en un momento determinado. En este caso, al no disponer de datos etiquetados para los registros de radiofrecuencia, se utilizó un modelo de red “profesor-estudiante” (*teacher-student*

network), en el que la red que actúa como “profesor” extrae una clasificación con datos etiquetados a través de frames RGB y utiliza este conocimiento para supervisar las conclusiones que la red que actúa como “estudiante” obtiene a través de mapas de calor verticales y horizontales.

Uddin et al. (2017) utilizaron *Deep Learning* y redes neuronales convolucionales partiendo de patrones de movimiento direccional extraídos de las siluetas de profundidad, que posteriormente se combinan con flujos de movimiento para general características robustas espaciotemporales.

Horst et al. (2019) pretenden paliar el principal problema que tienen las redes neuronales, es decir, la dificultad de explicar cómo han llegado a una conclusión determinada. Para ello genera redes neuronales profundas unida a la técnica de *Layer-Wise Relevance Propagation* que informa acerca de qué variable y en qué parte del ciclo de la marcha es el más característico para determinar el patrón de marcha de cada individuo.



## 2 Dispositivos comerciales existentes para la detección de movimiento

A continuación, se indican varios de los dispositivos comerciales que se utilizan en un entorno clínico para la medición del movimiento. Por similitud con la Sección 1, se realiza la misma clasificación en las diversas modalidades de dispositivos, haciendo especial énfasis en los dispositivos vestibles de tipo inercial.

### 2.1 Dispositivos no vestibles

#### 2.1.1 Sistemas de captura de movimiento

##### 2.1.1.1 Sistemas basados en marcadores

Existen varios sistemas profesionales que permiten detectar y analizar el movimiento humano mediante vídeo. Su funcionamiento se basa en un conjunto de cámaras de alta precisión que se colocan en posiciones determinadas para abarcar la mayor parte del espacio posible y que detectan la posición de las diferentes partes del cuerpo mediante marcadores colocados sobre el cuerpo (ya sea de manera directa o utilizando un traje especial).

Entre los sistemas de este tipo, pueden citarse los de **Vicon<sup>1</sup>**, **Contemplas<sup>2</sup>** y **BTS Gaitlab<sup>3</sup>**, **Clinical 3DMA<sup>4</sup>**. Los fabricantes de este tipo de sistemas suelen permitir personalizar la cantidad y el tipo de dispositivos a utilizar, de acuerdo a las necesidades de los análisis que se requieran. La principal ventaja de esta arquitectura es la gran cantidad de información analizada, de manera muy precisa. En el ámbito de la marcha permite no sólo obtener parámetros relacionados con la pisada, sino que se podría obtener información sobre el posicionamiento de la cadera y tronco superior. Como contraprestación, su **elevado coste** implica que una infraestructura de este tipo sólo pueda estar disponible en determinados laboratorios o clínicas. Su localización, por tanto, sería para un entorno interior y el rango de movimiento del paciente, si bien es superior a otros sistemas como el de **GAITRite**, no deja de estar limitado a un recinto cerrado de reducidas dimensiones.

<sup>1</sup> <https://www.vicon.com/motion-capture/life-sciences>

<sup>2</sup> <https://www.contemplas.com/index.aspx>

<sup>3</sup> <https://www.btsbioengineering.com/products/bts-gaitlab-gait-analysis/>

<sup>4</sup> <https://www.stt-systems.com/motion-analysis/3d-optical-motion-capture/clinical-3dma/>




Figura 2. Diferentes configuraciones del entorno de pruebas con sistemas de detección y análisis de movimiento a través de vídeo

### 2.1.1.2 **Sistemas no basados en marcadores**

El principal dispositivo comercial que se utiliza en este ámbito es el dispositivo **Kinect de Microsoft**. Se trata de un dispositivo desarrollado por Microsoft, inicialmente asociado a la **consola XBOX**, pero que puede aplicarse a cualquier entorno sin necesidad de uso de la consola, en lo que el fabricante denomina **“Kinect for Windows”**.



Figura 3. Kinect en su versión original (izquierda) y en la versión 2 (comercializada a partir de 2014)

No obstante, pese a su uso ampliamente extendido en la comunidad científica, a finales de 2018, según indica Microsoft en la web principal del producto para los desarrolladores<sup>5</sup>, **se ha suspendido la fabricación del adaptador y del sensor Kinect**. Desde la propia web de Microsoft se sugiere utilizar la tecnología de captación de imagen de las cámaras de profundidad **RealSense de Intel**<sup>6</sup>.

Microsoft ha querido darle un giro a la tecnología Kinect y se encuentra actualmente **evolucionando hacia el Azure Kinect DK**<sup>7</sup>, en el que se combinará una nueva gama de sensores de profundidad con los servicios de IA de Azure. Actualmente se encuentra disponible sólo para pruebas iniciales y no se ha proporcionado aún el SDK correspondiente que permitirá el desarrollo de nuevas aplicaciones.

<sup>5</sup> <https://developer.microsoft.com/es-es/windows/kinect>

<sup>6</sup> <https://software.intel.com/realsense>

<sup>7</sup> <https://azure.microsoft.com/es-es/services/kinect-dk/>



Figura 4. Azure Kinect DK

Existen varios sistemas comerciales que se basan en la tecnología Kinect para realizar análisis de la marcha, como MotionMetrix<sup>8</sup> y MotionReady<sup>9</sup>.

### 2.1.2 Plataformas de fuerza

Uno de los fabricantes especializado en el campo de las plataformas de fuerza para el análisis de la marcha es Kistler<sup>10</sup>. Esta compañía ofrece unas superficies con sensores piezoeléctricos capaces de medir la presión que ejerce el individuo y permiten detectar cambios en la forma de caminar o en el centro de gravedad. Se ofrecen comercialmente las plataformas de fuerza de manera individual, y teniendo en cuenta el tipo de pruebas que se deseen realizar, se deberá utilizar una cantidad diferente de las mismas para crear la superficie por la que el usuario deba caminar. Además, debe obtenerse el sistema de adquisición de datos (encargado de recoger todos los datos recogidos por los sensores) y, opcionalmente, el software para análisis de rendimiento. Otro de los fabricantes de dispositivos es Tekscan<sup>11</sup>, el cual ofrece también diversas opciones de configuración.

### 2.1.3 Superficies instrumentadas

El sistema GAITRite<sup>12</sup> es uno de los más utilizados en la actualidad en un entorno clínico y su validez como medio para cuantificar los parámetros espaciales y temporales de la marcha ha sido ampliamente demostrada en publicaciones científicas (Bilney et al. (2003), Menz et al. (2004)). Se trata de un sistema portátil basado en una superficie horizontal que se extiende sobre el suelo (con una longitud de 7 metros) equipado con una serie de sensores que recogen los resultados y los transmiten a un software específico que los analiza.

Los parámetros obtenidos por este software son, entre otros, el tiempo transcurrido en cada paso, longitud de zancada y velocidad, así como la distribución del peso durante la pisada. Su uso está solamente recomendado para interiores, y debe estar supervisado por un profesional clínico.

<sup>8</sup> <https://www.motionmetrix.se/4-technology/>

<sup>9</sup> <https://motionready.com.au/pages/about-motion-metrix>

<sup>10</sup> <https://www.kistler.com/en/applications/sensor-technology/biomechanics-and-force-plate/gait-analysis/>

<sup>11</sup> <https://www.tekscan.com/force-plate-pressure-technology>

<sup>12</sup> <https://www.gaitrite.com/>

En los últimos años, el fabricante ha desarrollado un nuevo producto (**GAITRite CIRFACE**) que permite varias configuraciones de la superficie para simular un escalón y permitir giros, ofreciendo mayor versatilidad. Actualmente se encuentra desarrollando el sistema **GAITRite SAFARI**, para su uso en exteriores. Otros sistemas de este tipo son las plataformas de **Bertec**<sup>13</sup>, **Medilogic**<sup>14</sup>, **Optogait**<sup>15</sup>.



Figura 5. Sistema GAITRite

## 2.2 Sistemas vestibles enfocados al entorno deportivo

Los sistemas de análisis de la marcha han evolucionado para dar cabida al mundo del deporte profesional, analizando factores durante la carrera que permiten detectar fallos posturales o localizar aspectos para mejorar el rendimiento deportivo. Aunque todos los sistemas de detección y análisis del movimiento a través del vídeo anteriores se aplican al deporte profesional se han desarrollado nuevos dispositivos que permiten análisis rigurosos de diferentes parámetros de forma más asequible, tanto en el precio como en la forma de llevar a cabo los experimentos.

Si bien el objeto de este proyecto no es el deportivo, cabe resaltar algunos dispositivos utilizados en el ámbito del atletismo puesto que, aunque muchas de las variables pueden no ser relevantes para la población objetivo de Pre-Fall, la forma de obtenerlas sí tiene características comunes, por lo que su análisis puede ofrecer características relevantes. Algunos de los más relevantes son los siguientes:

- Sensores que se acoplan al calzado, como el *RunScribe Pods*<sup>16</sup> o el *Sensor running Bluetooth Smart de Polar*<sup>17</sup>
- SmartTracks de Humotion<sup>18</sup>: sensor basado en un cinturón, que se coloca en la parte baja de la espalda.

<sup>13</sup> <https://www.bertec.com/products/portable-functional>

<sup>14</sup> <https://medilogic.com/en/platform-pro/>

<sup>15</sup> <http://www.optogait.com/>

<sup>16</sup> <https://runscribe.com/>

<sup>17</sup> [https://www.polar.com/es/productos/accesorios/Sensor\\_running\\_Bluetooth\\_Smart](https://www.polar.com/es/productos/accesorios/Sensor_running_Bluetooth_Smart)

<sup>18</sup> <https://humotion.net/en/products/smartracks/diagnostics/>



Figura 6. Sensor running Bluetooth Smart de Polar (izquierda) y SmartTracks de Humotion (derecha)

En este ámbito, existen también varios sensores integrados ya en diversos elementos:

- **SmartSocks de Sensoria<sup>19</sup>**: calcetines que permiten detectar posiciones incorrectas en las pisadas durante la carrera.
- **Plantillas que recogen** diferentes parámetros de la pisada, como las Lechal Smart Insoles<sup>20</sup>, las de Digisole<sup>21</sup>, FeetMeSport<sup>22</sup> o las de Arion<sup>23</sup>.



Figura 7. SmartSocks (izquierda) y Digisole (derecha)

No se puede afirmar que estos dispositivos aporten **información clínicamente validada** al dirigirse, únicamente, a recoger datos relacionados con la pisada durante la carrera para que el usuario mejore su modo de correr.

Cabe resaltar que todos los dispositivos identificados en el listado superior detectan características propias de la marcha, como la longitud de la zancada, excluyendo aquellos enfocados a la medición de otras características físicas que no tienen relevancia para el objetivo de Pre-Fall, por lo que no se han incluido en este análisis.

## 2.3 Otros sistemas basados en sensores inerciales

En la Sección 1 se han analizado diversos estudios para el modelado de la marcha humana que se basan en el uso de diferentes dispositivos de medición. Generalmente se basan en la unión de varios tipos de sensores vestibulares o dispositivos de captación de movimiento junto a una serie de algoritmos de aprendizaje para detectar patrones o características de la marcha. No se trata, sin embargo, de dispositivos comercializados, sino que estos estudios se centran en la validación clínica de dichos dispositivos en una serie de supuestos concretos o en la validación de sus algoritmos. De este modo, han surgido varios productos comerciales que se apoyan en estos

<sup>19</sup> <http://www.sensoriafitness.com/smartsocks/>

<sup>20</sup> <http://www.lechal.com/styles.html#>

<sup>21</sup> <https://www.digitsole.com/store/connected-insoles-running-run-profiler/>

<sup>22</sup> <https://feetmesport.com/en/index.php>

<sup>23</sup> <https://www.arion.run/wearable/>

estudios para demostrar su validez, siendo a menudo complejo determinar solamente con el estudio de las publicaciones científicas qué dispositivos comerciales se encuentran asociados a ellos.

De este modo, se ha complementado este análisis del estado del arte con una búsqueda de dispositivos comerciales que ofrezcan unas especificaciones similares a las buscadas en los objetivos de Pre-Fall, es decir, que ofrezcan algún tipo de captación de la marcha humana y un software de análisis ya integrado que aporte parámetros de la marcha relevantes para diagnosticar una posible enfermedad o problema de salud.

Destacamos a continuación varios dispositivos que cumplen estos requisitos:

### 2.3.1 LEGSys

Este sistema<sup>24</sup> permite dos tipos de configuraciones: la más sencilla utiliza 2 sensores en las pantorrillas y la más compleja utiliza, además, otros 2 sensores (en los muslos y bajo el pecho). A continuación, se indican las características más relevantes:

Tipo de sensores	Sensores inerciales
Tecnología de comunicación de los sensores	Bluetooth
Número y posición de los sensores	Dos tipos de configuraciones: 1. Dos sensores en las pantorrillas 2. Dos sensores en las pantorrillas, uno en los muslos y uno bajo el pecho
Tipo de pruebas soportadas	Timed Up and Go (TUG) Detecta la probabilidad de aparición de caídas
Tipo de software proporcionado	Software para Windows o Mac
Resultados generados	Características generales de la marcha (espaciales y temporales). En la configuración avanzada muestra además resultados del movimiento de pelvis y los ángulos de rodilla y cadera.

<sup>24</sup> <http://www.biosensics.com/products/legsys/>





Figura 8. LEGSys

### 2.3.2 Kinesis Gait

El sistema de Kinesis Gait<sup>25</sup> permite obtener las características de la marcha a partir de 2 sensores situados en las pantorrillas. A continuación, se indican las características más relevantes:

Tipo de sensores	Sensores inerciales
Tecnología de comunicación de los sensores	Bluetooth
Número y posición de los sensores	2 sensores en las pantorrillas
Tipo de pruebas soportadas	Permite cualquier tipo de test clínico de la marcha, por ejemplo: “Timed 25-foot walk” (test para caminar una distancia de 25 pies) Test para caminar durante 6 minutos) Test para caminar 6 o 30 metros
Tipo de software proporcionado	App
Resultados generados	Características generales de la marcha (espaciales y temporales).

<sup>25</sup> <https://www.kinesis.ie/gait/>




Figura 9. Kinesis GAIT

### 2.3.3 PhysiGait Live

Este sistema<sup>26</sup> se basa en el uso de 2 sensores que se acoplan al calzado. A continuación, se indican las características más relevantes:

Tipo de sensores	Sensores inerciales
Tecnología de comunicación de los sensores	No especificado
Número y posición de los sensores	2 sensores que se colocan por debajo del tobillo, por ejemplo en los cordones de los zapatos
Tipo de pruebas soportadas	Timed Up and Go (TUG) Detecta la probabilidad de aparición de caídas
Tipo de software proporcionado	App
Resultados generados	Características generales de la marcha (espaciales y temporales). Además, se proporcionan varios datos de ángulos y distancias de alzada del talón y puntera respecto al suelo al caminar.



Figura 10. PhysicaGait Live

### 2.3.4 iSen System

Este es uno de los sistemas más completos existentes<sup>27</sup> y permite obtener gran cantidad e información acerca de las posiciones de las distintas partes del cuerpo, por lo que se puede aplicar a múltiples ámbitos. A continuación, se indican las características más relevantes:

<sup>26</sup> <https://gaitup.com/gait-analysis/physigait-live/>

<sup>27</sup> <https://www.stt-systems.com/motion-analysis/inertial-motion-capture/isen/>



Tipo de sensores	Sensores inerciales. Cada sensor contiene un giroscopio en 3 ejes, acelerómetro y magnetómetro.
Tecnología de comunicación de los sensores	WiFi
Número y posición de los sensores	Diferentes configuraciones de los sensores, desde 1 a 16 sensores según los análisis que se quieran utilizar. es posible realizar el análisis de la marcha con un único sensor <sup>28</sup> .
Tipo de pruebas soportadas	No especificado. El software proporciona una guía de configuración que se adapta al número de sensores y a los objetivos de la medición.
Tipo de software proporcionado	Programa para Windows. Permite visualizaciones en 3D de las articulaciones.
Resultados generados	Características generales de la marcha (espaciales y temporales). Datos exportables en ASCII y CSV.

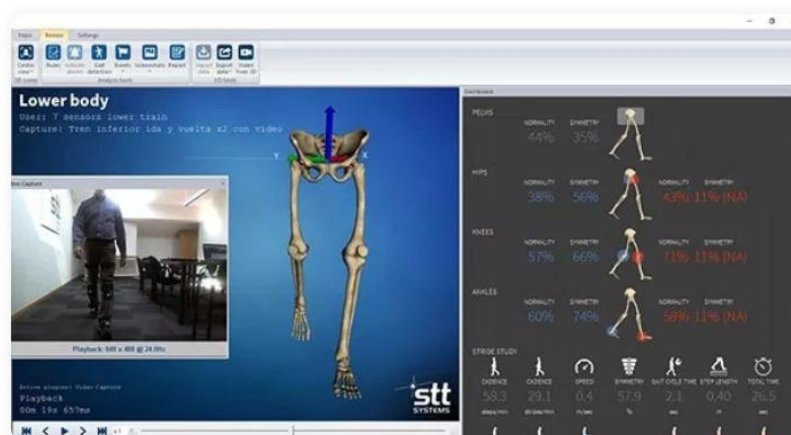


Figura 11. iSEN Systems

### 2.3.5 RehaGait

El sistema RehaGait<sup>29</sup> se ofrece en dos versiones con diferente número de sensores. A continuación, se indican las características más relevantes:

<sup>28</sup> <https://www.stt-systems.com/motion-analysis/inertial-motion-capture/>

<sup>29</sup> <https://www.rehagait.com>

<b>Tipo de sensores</b>	Sensores inerciales. Cada sensor contiene un acelerómetro en 3 ejes, un giroscopio en 3 ejes y un magnetómetro en 3 ejes.
<b>Tecnología de comunicación de los sensores</b>	No especificado
<b>Número y posición de los sensores</b>	El producto se ofrece en dos versiones: Versión simple, con 2 sensores que se acoplan al lateral de los zapatos. Versión profesional, con 7 sensores que se colocan en: <ul style="list-style-type: none"> <li>• 1 sensor alrededor de la cintura</li> <li>• 2 sensores por encima de las rodillas</li> <li>• 2 sensores por encima de los tobillos</li> <li>• 2 sensores en el lateral de los zapatos</li> </ul>
<b>Tipo de pruebas soportadas</b>	Optimizado para caminar una distancia de 20 metros
<b>Tipo de software proporcionado</b>	Tablet con software ya instalado.
<b>Resultados generados</b>	Características generales de la marcha (espaciales y temporales). Datos de ángulos y distancias dealzada del talón y puntera respecto al suelo al caminar. En la versión profesional se ofrecen datos relativos a los ángulos de los tobillos, rodillas y cadera.



Figura 12. RehaGait

### 2.3.6 G-Walk

El sistema G-Walk<sup>30</sup> aúna en un único sensor todo el análisis relevante de la marcha. A continuación, se indican las características más relevantes:

<sup>30</sup> <https://www.btsbioengineering.com/products/g-walk-inertial-motion-system>

<b>Tipo de sensores</b>	Sensor inercial. Compuesto por acelerómetro en 3 ejes, un giroscopio en 3 ejes y un magnetómetro en 3 ejes.
<b>Tecnología de comunicación de los sensores</b>	Bluetooth
<b>Número y posición de los sensores</b>	Un único sensor integrado en un cinturón y colocado en la parte baja de la espalda
<b>Tipo de pruebas soportadas</b>	Timed Up and Go test Test de caminar 6 minutos Caminar libremente (durante un máximo de 7 metros de distancia) Giro Carrera Saltos
<b>Tipo de software proporcionado</b>	No especificado
<b>Resultados generados</b>	Características generales de la marcha (espaciales y temporales).





Figura 13. G-Walk

### 3 Conclusiones

El estudio de la bibliografía existente ha determinado que existen multitud de métodos para la adquisición de los datos o imágenes que permitirán posteriormente un análisis de las características de la misma. Estos métodos se pueden basar tanto en dispositivos vestibles como en dispositivos no vestibles, a través de diferentes tecnologías. El análisis de los diferentes trabajos ha confirmado que todos los métodos aquí descritos tienen validez para el análisis de la marcha por lo que Pre-Fall puede constituirse utilizando sensores inerciales, como se planteaba en la propuesta de proyecto. Los sensores de este tipo tendrían la misma validez científica que un sistema de adquisición de imagen basado en marcadores, pero con un coste muchísimo menor y ofreciendo una mayor versatilidad.

## 4 Referencias

Andersson, V. O., & Araujo, R. M. (2015, February). Person identification using anthropometric and gait data from kinect sensor. In *Twenty-Ninth AAAI Conference on Artificial Intelligence*

Balazia, M., & Sojka, P. (2018). Gait recognition from motion capture data. *ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM)*, 14(1s), 22.

Bartlett HL, Ting LH, Bingham JT. Accuracy of force and center of pressure measures of the Wii Balance Board. *Gait Posture* (2014) 39:224-8. doi:10.1016/j.gaitpost.2013.07.010

Battistone, F., & Petrosino, A. (2018). TGLSTM: A time based graph deep learning approach to gait recognition. *Pattern Recognition Letters*.

Bilney, B., Morris, M., & Webster, K. (2003). Concurrent related validity of the GAITRite® walkway system for quantification of the spatial and temporal parameters of gait. *Gait & posture*, 17(1), 68-74.

Caldas, R., Mundt, M., Potthast, W., de Lima Neto, F. B., & Markert, B. (2017). A systematic review of gait analysis methods based on inertial sensors and adaptive algorithms. *Gait & posture*, 57, 204-210.

Camps, J., Sama, A., Martin, M., Rodriguez-Martin, D., Perez-Lopez, C., Arostegui, J. M. M., ... & Prats, A. (2018). Deep learning for freezing of gait detection in Parkinson's disease patients in their homes using a waist-worn inertial measurement unit. *Knowledge-Based Systems*, 139, 119-131.

Cantoral-Ceballos, J. A., Nurgiyatna, N., Wright, P., Vaughan, J., Brown-Wilson, C., Scully, P. J., & Ozanyan, K. B. (2014). Intelligent carpet system, based on photonic guided-path tomography, for gait and balance monitoring in home environments. *IEEE sensors Journal*, 15(1), 279-289.

Costilla-Reyes, O., Vera-Rodriguez, R., Scully, P., & Ozanyan, K. B. (2018). Analysis of spatio-temporal representations for robust footstep recognition with deep residual neural networks. *IEEE transactions on pattern analysis and machine intelligence*, 41(2), 285-296.

El-Attar, A., Ashour, A. S., Dey, N., Abdelkader, H., Abd El-Naby, M. M., & Sherratt, R. S. (2018). Discrete wavelet transform-based freezing of gait detection in Parkinson's disease. *Journal of Experimental & Theoretical Artificial Intelligence*, 1-17.

Hofmann, M., Geiger, Jurger, Bachmann, S, Schuller, B; Rigoll, G. (2014). The TUM Gait from Audio, Image, and Deph(GAID) database: Multimodal Recognition of

subjects and traits. *Journal of Visual Communication and Image Representation*. Volume 25, issue 1.

Horst, F., Lapuschkin, S., Samek, W., Müller, K. R., & Schöllhorn, W. I. (2019). Explaining the unique nature of individual gait patterns with deep learning. *Scientific reports*, 9(1), 2391.

Lee, S. S., Choi, S. T., & Choi, S. I. (2019). Classification of Gait Type Based on Deep Learning Using Various Sensors with Smart Insole. *Sensors*, 19(8), 1757.

López-Nava, I. H., Muñoz-Meléndez, A., Pérez Sanpablo, A. I., Alessi Montero, A., Quiñones Urióstegui, I., & Núñez Carrera, L. (2016). Estimation of temporal gait parameters using Bayesian models on acceleration signals. *Computer methods in biomechanics and biomedical engineering*, 19(4), 396-403.

Menz, H. B., Latt, M. D., Tiedemann, A., San Kwan, M. M., & Lord, S. R. (2004). Reliability of the GAITRite® walkway system for the quantification of temporo-spatial parameters of gait in young and older people. *Gait & posture*, 20(1), 20-25.

Meshkati Z, Namazizadeh M, Salavati M, Mazaheri M. Reliability of force-platform measures of postural sway and expertise-related differences. *J Sport Rehabil* (2011) 20:442-56. doi:10.1123/jsr.20.4.442

Mohammed, S., Same, A., Oukhellou, L., Kong, K., Huo, W., & Amirat, Y. (2016). Recognition of gait cycle phases using wearable sensors. *Robotics and Autonomous Systems*, 75, 50-59.

Moore, S. T., Yungher, D. A., Morris, T. R., Dilda, V., MacDougall, H. G., Shine, J. M., ... & Lewis, S. J. (2013). Autonomous identification of freezing of gait in Parkinson's disease from lower-body segmental accelerometry. *Journal of neuroengineering and rehabilitation*, 10(1), 19.

Paragliola, G., & Coronato, A. (2018). Gait Anomaly Detection of Subjects With Parkinson's Disease Using a Deep Time Series-Based Approach. *IEEE Access*, 6, 73280-73292.

Pogorelc, B., Bosnić, Z., & Gams, M. (2012). Automatic recognition of gait-related health problems in the elderly using machine learning. *Multimedia Tools and Applications*, 58(2), 333-354.

Sahak, R., Tahir, N. M., Yassin, I., & Zaman, F. H. H. K. (2018, September). Kinect-Based Frontal View Gait Recognition Using Support Vector Machine. In *Proceedings of SAI Intelligent Systems Conference* (pp. 521-528). Springer, Cham.

Seyfioğlu, M. S., Gürbüz, S. Z., Özbayoğlu, A. M., & Yüksel, M. (2017, May). Deep learning of micro-Doppler features for aided and unaided gait recognition. In *2017 IEEE Radar Conference (RadarConf)* (pp. 1125-1130). IEEE.

Shanahan, C. J., Boonstra, F., Cofré Lizama, L. E., Strik, M., Moffat, B. A., Khan, F., ... & Kolbe, S. C. (2018). Technologies for advanced gait and balance assessments in people with multiple sclerosis. *Frontiers in neurology*, 8, 708.

Shetty, S., & Rao, Y. S. (2016, August). SVM based machine learning approach to identify Parkinson's disease using gait analysis. In *2016 International Conference on Inventive Computation Technologies (ICICT)* (Vol. 2, pp. 1-5). IEEE.

Tan, D., Pua, Y. H., Balakrishnan, S., Scully, A., Bower, K. J., Prakash, K. M., ... & Clark, R. A. (2019). Automated analysis of gait and modified timed up and go using the Microsoft Kinect in people with Parkinson's disease: associations with physical outcome measures. *Medical & biological engineering & computing*, 57(2), 369-377.

Uddin, M. Z., Khaksar, W., & Torresen, J. (2017, November). A robust gait recognition system using spatiotemporal features and deep learning. In *2017 IEEE International Conference on Multisensor Fusion and Integration for Intelligent Systems (MFI)*(pp. 156-161). IEEE.

Wang, J., Chen, Y., Hao, S., Peng, X., & Hu, L. (2019). Deep learning for sensor-based activity recognition: A survey. *Pattern Recognition Letters*, 119, 3-11.

Zhao, M., Li, T., Abu Alsheikh, M., Tian, Y., Zhao, H., Torralba, A., & Katabi, D. (2018). Through-wall human pose estimation using radio signals. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 7356-7365).